

RAG

三代:

1. Native RAG (基础检索增强)

① 文档预处理与索引 (数据清洗, 切片, 库)
内容 → 库

② 检索 (相似度检索)
向量相似度方法

③ 拼接回答
要不要检索

(4.2) Advanced RAG (精细化优化的检索增强)

a. 存什么, 怎么问 (检索)
① 索引: 固定 → 语义, 分块 (章节, 段落, 段落等)
(滑动窗口: 多粒度索引)
② 文档 chunk 更丰富内容 (来源, 时间, 作者, 父子结点)

③ 查询, 用问题改写, 扩展, 拆分
(多路查询, 子问题分解, step-back, Prompting, Query Rewrite 等) 逐步

13. Modular RAG (Agentic RAG) 类

① 查询理解与路由模块
用户问题 → 需求 → 路由 → 问题回答
检索有效

② 多层检索与融合模块

③ 记忆与知识模块
反馈, 智慧判断, memory 总结归纳

④ 评估与治理模块 | 自动更新知识库

b. 取回相关内容 (检索后)
① rerank 或 LLM 精排
问题链 → 逐步

② 对检索结果进行筛选, 去重与压缩 (上列)

③ 轻量模型微调 → 依据检索结果回答