

RAG 模块 advanced RAG.

(1) 数据处理

知识库



① 多数据源、解析

(pdf, excel, word等)

python

pdf表格

↓
a. 表格处理 (pdfplumber等)

将表格 $\Rightarrow$ 结构化数据

b. 扫描件 (OCR) $\rightarrow$ 处理

c. 多格式统一, 归一化为 markdown

中间格式 换型处理

② 数据清洗 (消除噪声)

(页眉页脚, 重复内容, 格式残留等)

a. 规则过滤 (正则) 判断法

b. 去重 (文档内容去重, Sim Hash)

c. 质量打分 (长度, 完整性, 可读性) 引入

③ 知识更新 (时间, 版本号)

a. 哪些变了

b. 怎么更新 (全量, 增量更新) RAG 缓存, 对应文件

c. 旧版本如何处理 (保留 or 覆盖)

检索召回

① 分块策略: chunk $\uparrow$, context $\uparrow$

(外边中, 过大有噪声, 过上下文过大)

切块方法: i. 直接切 (设定 token 数, 直接切)

ii. 递归切 (切成大块后将大块不断切小)

语义切 (不按固定切, 按语义边界切)

段落中 $\rightarrow$ 句子

chunk $\uparrow$

ii. 父子文档 (大块文档作父节点, 小块 $\rightarrow$ 子节点, 定位到小块同时传大块)

10~15% $\rightarrow$ overlap (重叠切分, 相邻块留重叠量, 避免信息断裂)

② 语义不同 (用户提问与文档有差异)

讨论: 怎么记 overlap

优化提问内容: i. Query 改写/扩展 (LLM 优化问题内容)

ii. HyDE (LLM 生成假设性回答 $\rightarrow$ 检索) 小标题

iii. 混合检索: 关键词 (BM25) + 语义 (Embedding)

③ 召回取舍 (召回率与精确率平衡)

i. Rerank 重排序 (粗召回确保集合, rerank 确保对)

ii. 动态 K (依据问题类型动态调整 K 值)

生成回答

① 召回时，但 LLM 欺骗。
(虚假信息 与 真实信息混在一起)

- a. prompt 约束 (标注信息来源) SFT (偏好学习) 文档输入
- b. 引用溯源 (标注信息来源) LLM
- c. 后处理检查 (轻量 LLM 做交叉对比)
- d. 拒答机制 (置信度不够不答)

② Lost in the middle (context)
a. 文档排序 (最相关内容放在上下文首尾 或 只用最相关文档内容)

b. Rerank 后取 top-N
c. 上下文利用不够 (利用文档内容过少)

- a. prompt 约束
- b. 分解回答 (复杂问题 → 子问题, 针对子问题作检索回答)

c. 引用溯源

总 RAG 流程

