1⃣ RAG

① 数据处理.

a. 结构化PDF → pdfplumber表格提取.

b. 扫描版PDF → OCR (Tesseract / PaddleOCR)

c. 复杂排版PDF → Unstructured库或多模态模型

d. word / PPT → Apache Tika

e. HTML页面 → 清洗HTML标签留正文

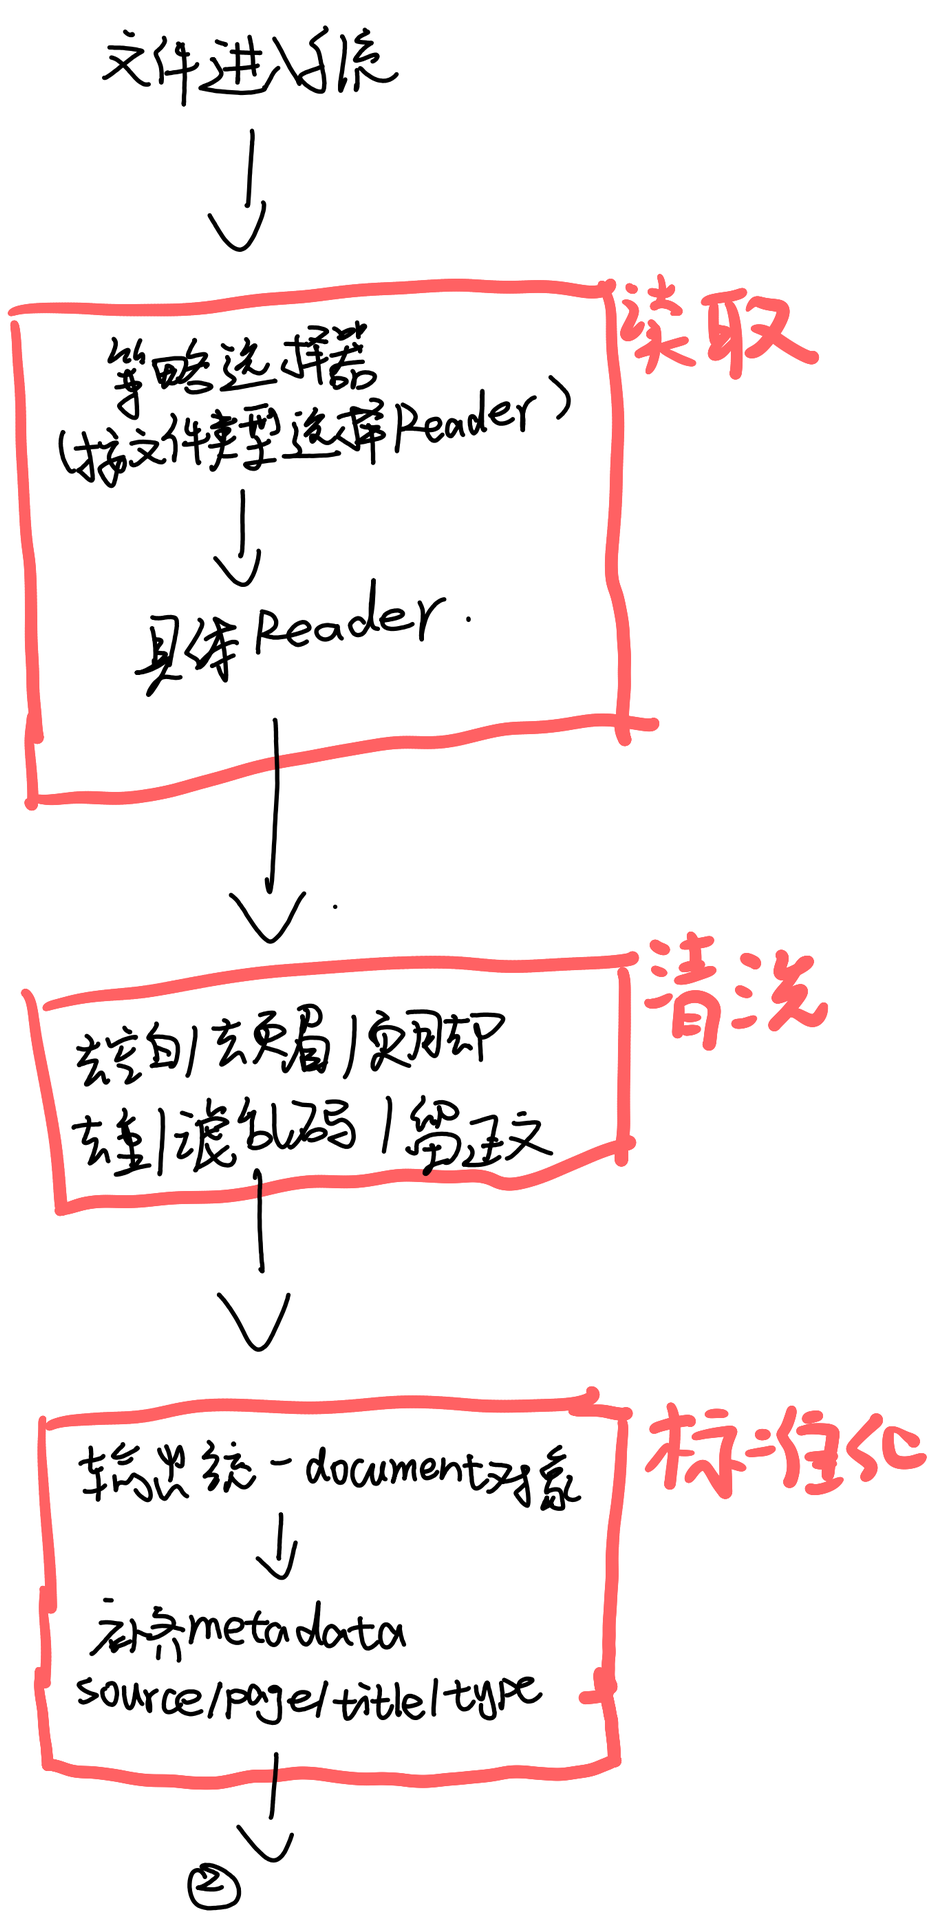
f. 代码文件 → 函数/类等AST感知切分

i. 子块更表精度，父块更表补充上文

parent_id

ii. 每个块都携带 repo、branch、commit.路径、ACL等元数据

iii. 按身份、版本过滤再继续



② 检索召回

a. chunk-size 选择

技术 — 500~1000字

新闻 — 300~500字.

法律合同 — 按条款

代码文档 — 按函数/类.

通常 500~1000字. overlap为size 10%~20%

(调试集进行调试)

b. 切块方式选择

i. 固定大小切块 — 数字等强切

ii. 递归分块 — 按照一组分隔符的优先级切

(如. 1. \n\n 2. \n 3. 。!? 4. ， 5. 口).

iii. 文档结构 (markdown. word).

iiii. 语义分块

iiiii. LLM智能切

d. 调优方法.

i. 经验

ii. 准备调试集

iii. 调参验证

iiii. 观察bad case

c. 添加元数据

1) 文档标识

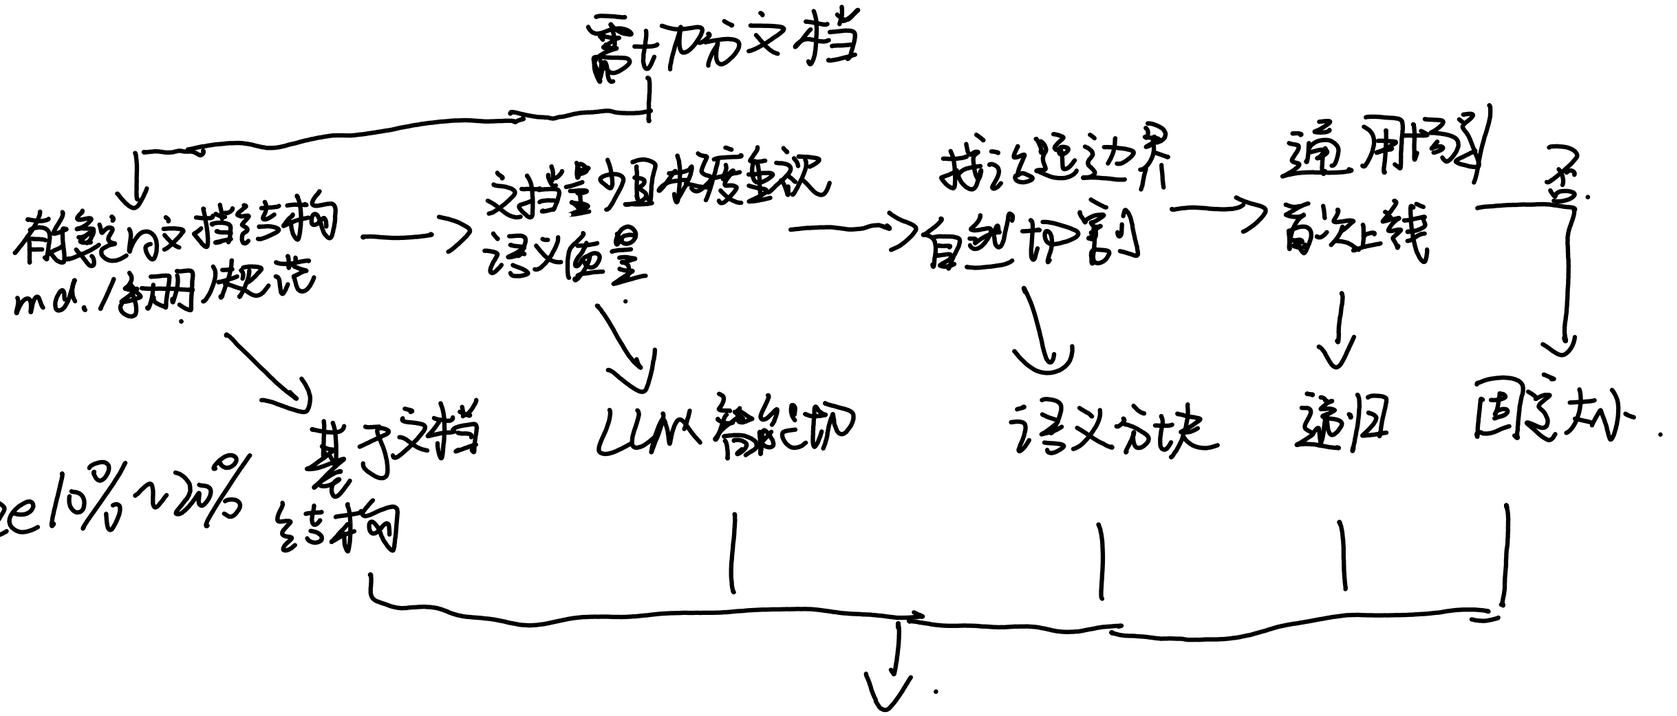
2) 段落引一结构信息

3) 时间戳一版本信息

4) 权限控制

5) 位置追溯

6) 自定义标签.



chunk_size、overlap

↓加元数据

抽样评估召回率、噪音、上下文完整性

↓

仍有漏句或漏召回

↓调优.

尝试更改切换方法

↓

输出.

e. Embedding <=> 将文字 → 高维数值向量.

ii. 向量相似度计算

1) 余弦相似度(常用)

$= \frac{\vec{A}\cdot\vec{B}}{|\vec{A}|\cdot|\vec{B}|} \in [-1,1]$.

2) 欧几里得距离(空间中两点距离)

例: $d = \sqrt{(x_2-x_1)^2+(y_2-y_1)^2}$

3) 点积

$\vec{A}\cdot\vec{B}$

用户问题 → 编码 → Embedding模型 → 查询向量 → 余弦相似度计算 → 前k片段

库

知识库文档 → 编码 → Embedding → 向量库(文本块+向量+元数据)

(1英文token ≈ 0.75个单词. 1中文token ≈ 1个汉字).

iii. Embedding模型选型.

1) 两个核心参数: 维度与上下文长度.

特征数量

2) 来源: 通过对应的排行榜与评估基准(MTEB, HuggingFace MTEB Leaderboard)

3) 数据 { 私密 / 语言

iii. 向量数据库

1) 与传统数据库的差别

2) 具体类型

iiii. rerank模型(可与embedding一致也可不同)：其他：BRF、RankLLM、ColBERT重排
Agent set Reranker leaderboard，一般为cross-Encoder

⑤生成回答
a. 问题改写
i 指代消解一把它变成真名
ii. 上下文补全一省略信息补齐
iii. 口语转书面
iiii. 多问题拆分(2-4个)
iiiii. 假设性回答任务(HyDE)
iiiiii. 追步提示

b. 意图识别与路由分发.
i. LLM 意图识别.
ii. 嵌入相似性路由. => 数据库路由 / 组件路由 / 提示词模板路由.
iii. 规则
iiii. jeV.

C. 评估

一. 检索评估

指标: Hit@K = 命中问题数 / 总测试问题数.

MRR = $\frac{1}{|Q|}\sum_{q=1}^{|Q|}\frac{1}{rank_q}$

(平均倒数排名)

Precision@k = 检索k个中相关的 / k

(检索精确率)

Recall@k = 前k个结果中相关文档数 / 数据集中的所有相关文档.

(检索召回率)

F1分数 = 2 · $\frac{P \times R}{P+R}$

(调和平均数)

二. 响应评估

1) 评估维度.

忠实度同答案

答案相关性

2) 评估方法

①LLM-as-judge

RAGAS本框架
- Faithfulness: 是否编造
- Answer Relevancy: 是否与问题相关
- Context Recall: 是否覆盖全
- Context Precision: 有用内容是否在前面.
- Factual Correctness: 回答事实是否与标答一致的.

LlamaIndex Evaluation

Phoenix (Arize).

②指标(需在数据集中有正确答案答案).

ROUGE-N = 匹配n-gram量 / 标答案n-gram量. (召回)

BLEU = BP × exp($\sum_{n=1}^{N} w_n \log p_n$ (精确)

惩罚因子.

METEOR = F_{mean} × (1 − Penalty) → 考虑语序惩罚项

$F_{mean} = \frac{P \times R}{\alpha P + (1-\alpha) R}$

线上评估：
点踩率（Thumbs Down Rate）
追问率（Follow-up Rate）
转人工率（Escalation Rate）
空回答率（Empty Answer Rate）
会话解决率（Resolution Rate）

测试集建立（代表性、标准化、可演化）
开始：整理50~100个高频问题及标准答案
持续：积累线上用户问答及标准答案；边界case
定期刷新：知识库内容、测试集

实验流程：明确评估目标 → 建立评估数据集 → 记录标准化运行数据 → 运行基线实验 → 分层分析结果 → 分析Bad case → 设置回归门槛